

EXAMEN (ESTIMATION) : CORRIGÉ SUCCINCT

I.Nikiforov

5 décembre 2002

Exercice 1 (2 points) Soit ξ une variable aléatoire continue issue d'une loi P dont la fonction de répartition est $F_\xi(x)$ et la densité de probabilité est $f_\xi(x)$. Définir la classe des toutes les variables aléatoires ξ , telles que

$$\mathbb{E}(\xi^{2002}) = 0.$$

Réponses : Cette classe est définie par les fonctions de répartition $F_\xi(x)$ ou les densités de probabilité $f_\xi(x)$ satisfaisant les équations suivantes

$$\mathbb{E}(\xi^{2002}) = \int_{-\infty}^{\infty} x^{2002} dF_\xi(x) = \int_{-\infty}^{\infty} x^{2002} f_\xi(x) dx = 0 \quad \text{et} \quad \int_{-\infty}^{\infty} f_\xi(x) dx = 1.$$

On peut remarquer que cette classe est très restreinte : les variables aléatoires ξ , de cette classe ont toute la «masse» probabiliste concentrée en 0. Donc, elles sont des constantes : $\xi = 0$ avec $\mathbb{P}(\xi = 0) = 1$.

Exercice 2 (9 points) À partir des observations y_1, y_2, \dots, y_n et x_1, x_2, \dots, x_n , on retient le modèle non linéaire suivant

$$y_i = x_i \log \theta + \xi_i, \quad i = 1, 2, \dots, n,$$

où $\theta > 0$ est le paramètre du modèle et $\xi_i \sim \mathcal{N}(0, \sigma^2)$, $\sigma^2 > 0$, est un bruit normal indépendant. On considère que les valeurs (déterministes) x_1, x_2, \dots, x_n sont choisies de telle sorte que $\sum_{i=1}^n x_i^2 > 0$.

1. Donner l'expression de la log-vraisemblance pour le modèle retenu.
2. Déterminer l'estimateur $\hat{\theta}$ du maximum de vraisemblance (MV) du paramètre θ .
3. L'estimateur MV $\hat{\theta}$ est-il biaisé ?
4. L'estimateur MV $\hat{\theta}$ est-il asymptotiquement biaisé ?
5. Vérifier les conditions de régularité $r1$ et $r2$ du Théorème de Rao-Cramer. Calculer (si les conditions $r1$ et $r2$ sont satisfaites) la borne de Rao-Cramer (en précisant la classe d'estimateurs).

Réponses :

1. En utilisant le fait que

$$y_i - x_i \log \theta = \xi_i \quad (\sim \mathcal{N}(0, \sigma^2))$$

on trouve logarithme de la fonction de vraisemblance

$$\begin{aligned} \log f(\theta; y_1, \dots, y_n) &= \log \left\{ \frac{1}{(\sqrt{2\pi})^n \sigma^n} \prod_{i=1}^n \exp \left[-\frac{(y_i - x_i \log \theta)^2}{2\sigma^2} \right] \right\} \\ &= n \log \frac{1}{\sigma \sqrt{2\pi}} - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i \log \theta)^2. \end{aligned}$$

2. Pour déterminer l'estimateur MV de θ il faut maximiser la fonction $\theta \mapsto \log f(\theta; y_1, \dots, y_n)$.

- Condition nécessaire d'extremum local : pour trouver le (les) point critique $\hat{\theta}$ on résoudra l'équation normale

$$\frac{\partial \log f(\theta; y_1, \dots, y_n)}{\partial \theta} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - x_i \log \theta) \frac{x_i}{\theta} = 0.$$

D'où on obtient l'estimateur MV $\hat{\theta}$ du paramètre θ

$$\hat{\theta} = \exp \left\{ \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2} \right\}.$$

- Condition suffisante d'extremum local :

$$\begin{aligned} \frac{\partial^2}{\partial \theta^2} \{\log f(\theta; y_1, \dots, y_n)\} &= \frac{\partial}{\partial \theta} \left\{ \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - x_i \log \theta) \frac{x_i}{\theta} \right\} \\ &= -\frac{1}{\sigma^2 \theta^2} \sum_{i=1}^n y_i x_i - \frac{1}{\sigma^2 \theta^2} \sum_{i=1}^n x_i^2 + \frac{\log \theta}{\sigma^2 \theta^2} \sum_{i=1}^n x_i^2. \end{aligned}$$

En remplaçant θ par $\hat{\theta}$ on obtient

$$\frac{\partial^2}{\partial \theta^2} \{\log f(\hat{\theta}; y_1, \dots, y_n)\} = -\frac{1}{\sigma^2 \hat{\theta}^2} \sum_{i=1}^n x_i^2 < 0.$$

Donc, la fonction $\theta \mapsto \log f(\theta; y_1, \dots, y_n)$ admet en $\hat{\theta}$ un maximum. Maintenant il est clair pourquoi nous avons exigé que $\sum_{i=1}^n x_i^2 > 0$.

3. Soit $\zeta = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2}$. L'espérance mathématique de ζ est

$$\mathbb{E}(\zeta) = \mathbb{E} \left(\frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2} \right) = \frac{\sum_{i=1}^n \mathbb{E}(y_i) x_i}{\sum_{i=1}^n x_i^2} = \frac{\sum_{i=1}^n x_i^2 \log \theta}{\sum_{i=1}^n x_i^2} = \log \theta.$$

Donc, on a $\zeta \sim \mathcal{N}(\log \theta, \sigma_\zeta^2)$. Maintenant on calcule l'espérance de $\hat{\theta}$:

$$\begin{aligned} \mathbb{E}(\hat{\theta}) &= \mathbb{E}(\exp\{\zeta\}) = \int_{-\infty}^{\infty} e^x \frac{1}{\sigma_\zeta \sqrt{2\pi}} e^{-\frac{(x - \log \theta)^2}{2\sigma_\zeta^2}} dx \\ &= \int_{-\infty}^{\infty} \frac{1}{\sigma_\zeta \sqrt{2\pi}} e^{-\frac{x^2 - 2x(\log \theta + \sigma_\zeta^2) + (\log \theta + \sigma_\zeta^2)^2 - (\log \theta + \sigma_\zeta^2)^2 + (\log \theta)^2}{2\sigma_\zeta^2}} dx \\ &= e^{\frac{(\log \theta + \sigma_\zeta^2)^2 - (\log \theta)^2}{2\sigma_\zeta^2}} \underbrace{\int_{-\infty}^{\infty} \dots dx}_{=1} = e^{\log \theta + \sigma_\zeta^2/2} = \theta e^{\sigma_\zeta^2/2} \neq \theta \end{aligned}$$

Donc, l'estimateur MV $\hat{\theta}$ est biaisé.

4. La variance σ_ζ^2 de la variable aléatoire ζ est

$$\sigma_\zeta^2 = \text{var}(\zeta) = \text{var} \left(\frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2} \right) = \frac{\sum_{i=1}^n \text{var}(y_i) x_i^2}{\left(\sum_{i=1}^n x_i^2 \right)^2} = \frac{\sigma^2 \sum_{i=1}^n x_i^2}{\left(\sum_{i=1}^n x_i^2 \right)^2} = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}.$$

Soit $\lim_{n \rightarrow \infty} \sum_{i=1}^n x_i^2 = \infty$, alors $\sigma_\zeta^2 \rightarrow 0$. On obtient

$$\lim_{n \rightarrow \infty} e^{\log \theta + \sigma_\zeta^2/2} = e^{\log \theta} = \theta$$

et donc l'estimateur MV $\hat{\theta}$ est asymptotiquement non biaisé. (Par contre, si $\lim_{n \rightarrow \infty} \sum_{i=1}^n x_i^2 < \infty$, alors l'estimateur MV $\hat{\theta}$ est même asymptotiquement biaisé !)

5. Soit

$$f(\theta; y_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{(y_i - x_i \log \theta)^2}{2\sigma^2} \right\}.$$

La conditions de régularité r1 du Théorème de Rao-Cramer : la fonction $\theta \mapsto \sqrt{f(\theta; y_i)}$ est dérivable car c'est un produit ou composition des fonctions élémentaires. La dérivée

$$\frac{\partial \sqrt{f(\theta; y_i)}}{\partial \theta} = \frac{1}{2\sqrt{f(\theta; y_i)}} \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{(y_i - x_i \log \theta)^2}{2\sigma^2} \right\} \frac{y_i - x_i \log \theta}{\sigma^2} \left(\frac{x_i}{\theta} \right)$$

est continue comme produit ou composition des fonctions élémentaires ($\theta > 0$).

La conditions de régularité r2 du Théorème de Rao-Cramer :

$$\mathcal{F}(\theta) = \mathbb{E}_\theta \left[\left(\frac{\partial \log f(\theta; y_1, \dots, y_n)}{\partial \theta} \right)^2 \right] = \frac{1}{\theta^2 \sigma^2} \sum_{i=1}^n x_i^2.$$

La fonction $\theta \mapsto \mathcal{F}(\theta)$ existe, strictement positive et continue par rapport à θ (car $\theta > 0$ et $\sum_{i=1}^n x_i^2 > 0$). Soit

$$b(\theta) = \mathbb{E}(\hat{\theta}) - \theta = \theta \left(e^{\sigma_\zeta^2/2} - 1 \right), \text{ alors } b'(\theta) = e^{\sigma_\zeta^2/2} - 1.$$

On obtient la borne de Rao-Cramer dans la classe \mathcal{K}_b :

$$\mathbb{E}[(\hat{\theta} - \theta)^2] = \frac{\theta^2 \sigma^2}{\sum_{i=1}^n x_i^2} \exp \left\{ \frac{\sigma^2}{2 \sum_{i=1}^n x_i^2} \right\} + \theta^2 \left(\exp \left\{ \frac{\sigma^2}{2 \sum_{i=1}^n x_i^2} \right\} - 1 \right)^2.$$

Exercice 3 (5 points) Soit le modèle autorégressif (AR) suivant

$$y_t = \alpha y_{t-1} + (1 - \alpha)m + \xi_t, \quad t \geq 1$$

où $\xi_t \sim \mathcal{N}(0, \sigma_\xi^2)$ est un bruit normal indépendant et $y_0 \sim \mathcal{N}\left(m, \frac{\sigma_\xi^2}{1-\alpha^2}\right)$. Ce modèle AR a trois paramètres : m , $|\alpha| < 1$ et $\sigma_\xi^2 > 0$. Supposons que ces paramètres sont connus.

1. Calculer l'espérance mathématique et la variance de y_t pour $t \geq 1$.
2. On cherche un estimateur de y_{t+1} à base de y_t (problème d'extrapolation). Pour résoudre ce problème on utilise l'approche bayésienne.
Déterminer l'estimateur bayésien \hat{y}_{t+1} de y_{t+1} , c'est-à-dire l'espérance mathématique conditionnelle de la variables aléatoire y_{t+1} par rapport à y_t .
3. L'estimateur bayésien \hat{y}_{t+1} est-il biaisé ?
4. Calculer l'erreur moyenne quadratique $\mathbb{E}(\hat{y}_{t+1} - y_{t+1})^2$.

Réponses :

1. Soit $t = 1$. En utilisant le fait que $y_1 = \alpha y_0 + (1 - \alpha)m + \xi_1$ et $y_0 \sim \mathcal{N}\left(m, \frac{\sigma_\xi^2}{1-\alpha^2}\right)$, on obtient $\mathbb{E}(y_1) = \alpha\mathbb{E}(y_0) + (1 - \alpha)m + 0$. Donc, $\mathbb{E}(y_1) = m$. Ensuite, pour $t > 1$, on a $\mathbb{E}(y_t) = \alpha\mathbb{E}(y_{t-1}) + (1 - \alpha)m$ et finalement $\mathbb{E}(y_t) = m$ pour $t \geq 1$.

Soit $t = 1$. Alors $\text{var}(y_1) = \alpha^2 \text{var}(y_0) + \text{var}(\xi_1)$ (car le bruit est indépendant et donc $\text{cov}(y_{t-1}, \xi_t) = 0$ pour $t \geq 1$). On obtient $\text{var}(y_1) = \frac{\sigma_\xi^2}{1-\alpha^2}$. Ensuite, pour $t > 1$, on a $\text{var}(y_t) = \alpha^2 \text{var}(y_{t-1}) + \sigma_\xi^2$ et finalement $\text{var}(y_t) = \frac{\sigma_\xi^2}{1-\alpha^2}$ pour $t \geq 1$.

2. L'estimateur bayésien \hat{y}_{t+1} de y_{t+1} est donné par l'équation suivante

$$\hat{y}_{t+1} = \mathbb{E}(y_{t+1}|y_t) = \mathbb{E}(\alpha y_t + (1 - \alpha)m + \xi_{t+1}|y_t) = \alpha y_t + (1 - \alpha)m \underbrace{\mathbb{E}(\xi_{t+1}|y_t)}_{=0, \text{ car le bruit est indépendant}} = \alpha y_t + (1 - \alpha)m.$$

- 3.

$$\mathbb{E}(y_{t+1} - \hat{y}_{t+1}) = \mathbb{E}(y_{t+1} - \alpha y_t + (1 - \alpha)m) = \mathbb{E}(\xi_{t+1}) = 0.$$

Donc l'estimateur bayésien \hat{y}_{t+1} de y_{t+1} est non biaisé.

4. D'après la question 3 l'erreur moyenne quadratique est $\mathbb{E}(\hat{y}_{t+1} - y_{t+1})^2 = \mathbb{E}(\xi_{t+1})^2 = \sigma_\xi^2$.

Exercice 4 (4 points) Soit ξ_1, \dots, ξ_n n variables aléatoires indépendantes. La variable aléatoire ξ_i est issue de la loi P_θ dont la densité de probabilité est

$$f_\theta(y) = \begin{cases} \frac{3y^2}{8\theta^3} & \text{si } y \in [0, 2\theta] \\ 0 & \text{si } y \notin [0, 2\theta] \end{cases} \quad \theta \in]0; \infty[,$$

où θ est un paramètre inconnu.

1. Trouver un estimateur du paramètre θ par la méthode de moments. Utiliser le moment d'ordre 1.
2. L'estimateur par la méthode de moments est-il sans biais ?
3. Est-il asymptotiquement normal ?

Réponses :

- 1.

$$\mathbb{E}(\xi) = \int_0^{2\theta} y \frac{3y^2}{8\theta^3} dy = \frac{3y^4}{32\theta^3} \Big|_0^{2\theta} = \frac{3}{2}\theta.$$

L'estimateur du paramètre θ par la méthode de moments est :

$$\hat{\theta} = \frac{2}{3n} \sum_{i=1}^n \xi_i$$

- 2.

$$\mathbb{E}(\hat{\theta}) = \mathbb{E}\left(\frac{2}{3n} \sum_{i=1}^n \xi_i\right) = \theta.$$

3. L'estimateur $\hat{\theta}$ est asymptotiquement normal puisque la fonction $u \mapsto 2/3u$ est dérivable, $0 < 2/3 < \infty$ et le moment d'ordre 2 est fini :

$$\mathbb{E}(\xi^2) = \int_0^{2\theta} y^2 \frac{3y^2}{8\theta^3} dy = \frac{3y^5}{40\theta^3} \Big|_0^{2\theta} = \frac{12}{5}\theta^2 < \infty.$$